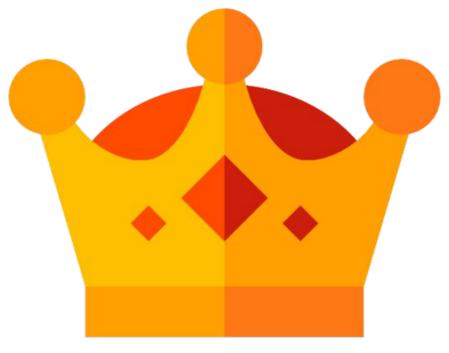
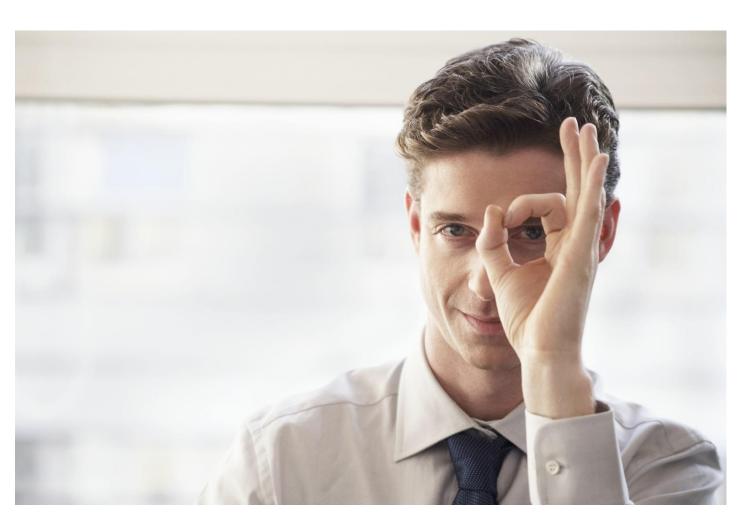
Credit Card Lead Prediction



Credit Predict



AI資料科學專業人才養成班[第三期]

團隊分工



CMO王之璇 資料前處理、結語 明志科技大學 工業工程與管理系



COO陳品臻 資料前處理 高雄大學 應用化學系





CTO蘇柏羽 Line bot後端 銘傳大學 資訊工程學系



CEO王育倫 Line bot前端 銘傳大學 資訊工程學系





Credit Predict

製作動機

- 1. 找尋潛在商機
- 2 降低人力成本
- 3. 提升客戶好感度

富邦先生

人物特色:沒有想法, 老實

人物背景:久久沒升遷的小主管

人物問題:想為銀行增加獲利,減少成本

人物需求:找尋淺在需求

終極目標:推算顧客對購買新銀行服務的與否

對使用者體驗的目標:推銷在對的顧客上

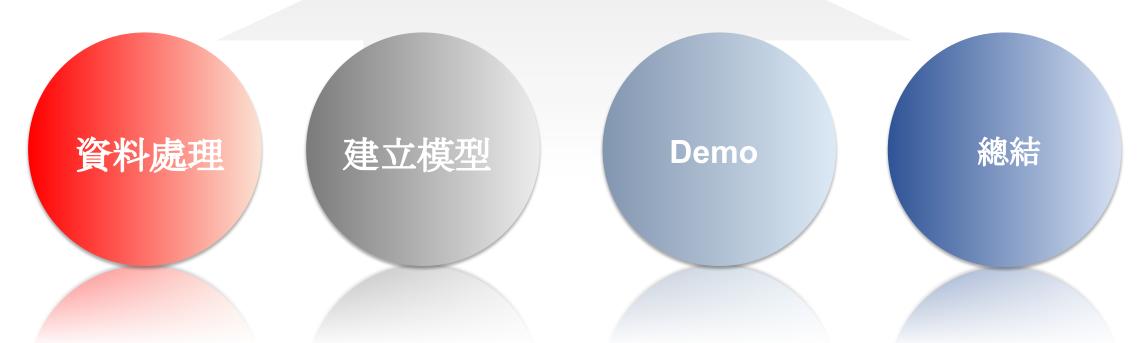
《問題討論

- → 何種因素(特徵值), 會影響到人們是否有 興趣
- → 基於因素(特徵值), 建立模型, 並利用模型預測潛在顧客的與否





Processing







資料前處理

資料比較

1 資料處理

2 建立模型

3 DEMO





資料類型

```
dataset.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 245725 entries, 0 to 245724
Data columns (total 11 columns):
    Column
                         Non-Null Count
                                         Dtype
                         245725 non-null object
    ID
    Gender
                         245725 non-null object
                         245725 non-null int64
    Age
    Region Code
                         245725 non-null object
    Occupation
                         245725 non-null object
    Channel Code
                         245725 non-null object
    Vintage
                         245725 non-null int64
                         216400 non-null object
    Credit Product
    Avg_Account_Balance 245725 non-null int64
    Is_Active
                         245725 non-null object
10 Is Lead
                         245725 non-null int64
dtypes: int64(4), object(7)
memory usage: 20.6+ MB
```



ID

Gender

Age

Region_Cod (

Occupation

客戶名稱

客戶性別

客戶年齡

郵遞區號

職業類別

Channel_Cod e

_Cod Vintage

Credit_Produ ct Avg_Accoun t_Balance

Is_Active

銀行代號

客戶存在 (月份)

是否已有 銀行服務 資產

是否活耀

Is_Lead

是否有興趣





資料前處理

資料比較

1 資料處理

2 建立模型

3 DEMO

总包括

Credit Predict

類別資料

```
#Gender_mapping $\frac{1}{2} Gender

Gender_mapping = {'Male':1, 'Female':0}

dataset['Gender'] = dataset['Gender'], map(Gender_mapping)
```

```
#將值轉換

occupation_mapping={"Entrepreneur":0, "Salaried":1, "Self_Employed":2, "Other":3}

traindata['Occupation'] = traindata['Occupation']. map(occupation_mapping)

traindata. head()
```

Channel code

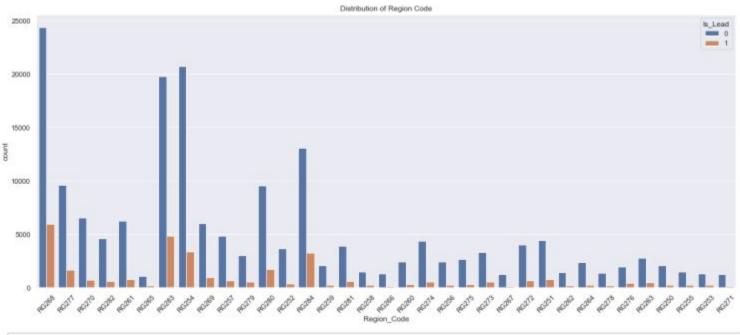
```
#Channel_Code_mapping數字
Channel_Code_mapping = {'X1':2, 'X3':1, 'X2':0, 'X4':0}
dataset['Channel_Code'] = dataset['Channel_Code'].map(Channel_Code_mapping)
```

Is_Active

```
#Is_Active_mapping數字
Is_Active_mapping = {'Yes':1, 'No':0}
dataset['Is_Active'] = dataset['Is_Active'].map(Is_Active_mapping)
```



Region_code



```
#依年齡區間做mapping function
Region mapping= {"RG268":1, "RG283":2, "RG254":3, "RG284":4, "RG277":5, "RG280":6, "RG269":7,
                 "RG270": 8, "RG261": 9, "RG257": 10, "RG251": 11, "RG282": 12, "RG274": 13, "RG272": 14,
                 "RG281":15, "RG273":16, "RG252":17, "RG279":18, "RG263":19, "RG275":20, "RG260":21,
                 "RG256": 22, "RG264": 23, "RG276": 24, "RG259": 25, "RG250": 26, "RG255": 27, "RG258": 28,
                 "RG253": 29, "RG278": 30, "RG262": 31, "RG266": 32, "RG265": 33, "RG271": 34, "RG267": 35 }
traindata['Region_Code'] = traindata['Region Code'].map(Region mapping)
#目前的datafram
traindata, head ()
```

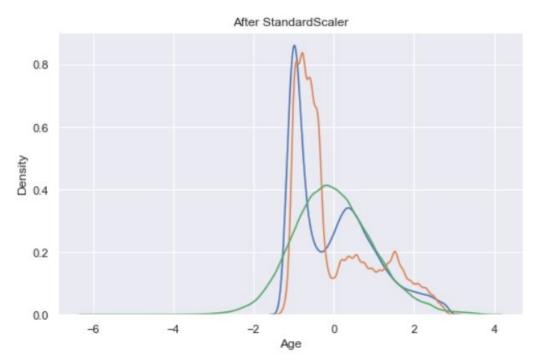


Credit Predict

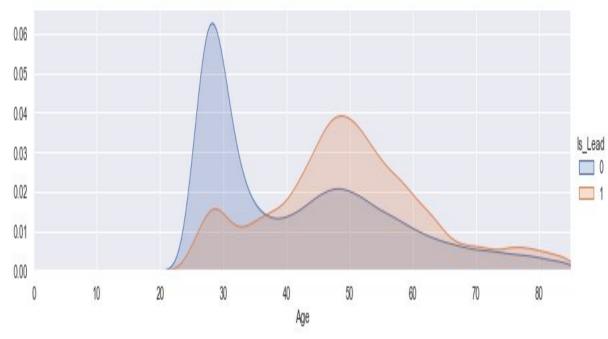
資料前處理

Age 66方法二

66方法一



將Age標準化

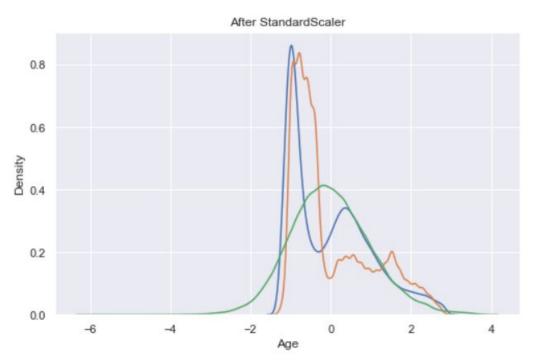


將Age按圖依特徵區分

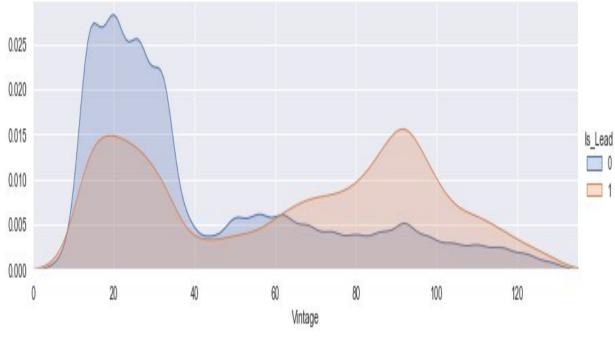


Vintage 《方法二

66方法一



將Vintage標準化

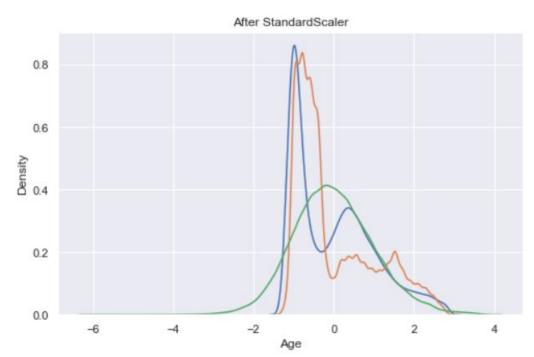


將Vintage按圖依特徵區分



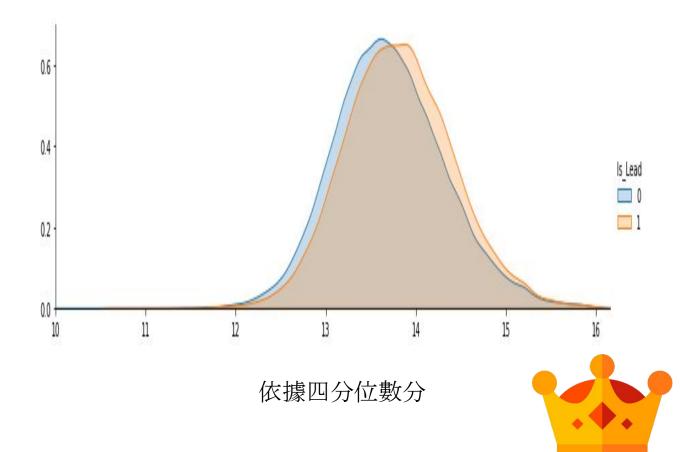
Avg_Account_Balance

66方法一



將Avg_Account_Balance 標準化

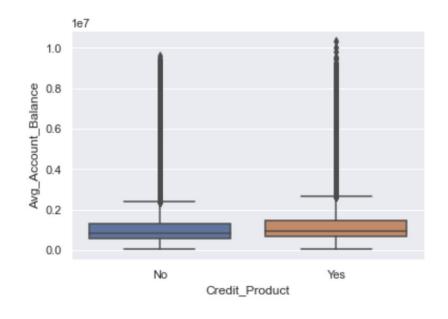
66方法二

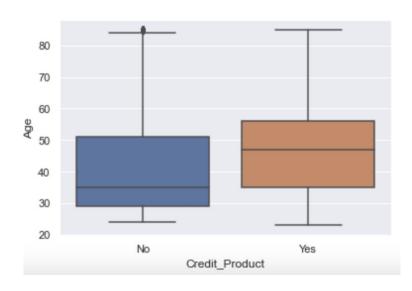


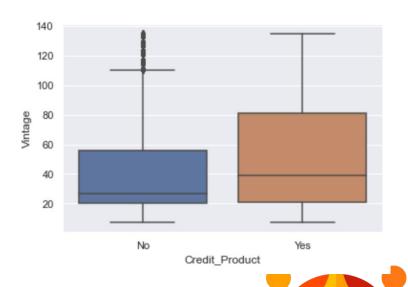
Credit Predict

空值處理

66 方法一







Credit Predict

資料前處理

空值處理

66方法一

找NA null indices = dataset[dataset['Credit Product'].isnull() == True].index

```
# 補值函式

def fill_na(data, null_indices):
    for i in null_indices:
        if (55 <= dataset['Age'].iloc[i] <=60) and (6
            dataset['Credit_Product'].iloc[i] = "Yes"
        elif 30 <= dataset['Age'].iloc[i] <= 40:
            dataset['Credit_Product'].iloc[i] = "No"
        else:
            dataset['Credit_Product'].iloc[i] = "Unkown"

# 補值
fill na(dataset, null indices)
```

Credit_Product_mapping = {'Unkown':2, 'Yes':1, 'No':0 }

66方法二

#missingvalue null_indices=traindata[traindata['Credit_Product'].isnull()==True].index

HIJERNAN | s": |="Yes | No": |="No"

traindata['Credit_Product'].iloc[i]="Unknow"

fill_na(traindata,null_indices)

Credit_mapping={"No":0,"Yes":1}

模型準確 度:84.79% 模型準確 度:80.77%



資料比較

同一參數						
	資料離散化	連續資料標準化	只對數值資料標準			
LogisticRegression	85.04%	85.03%	85.03%			
SGDClassifier	84.77%	84.96%	85.03%			
KNeighbors Classifier	85.19%	85.46%	85.31%			
GaussianNB	80.64%	80.15%	80.15%			
MultinomialNB	84.63%	84.63%				
BernoulliNB	82.26%	84.64%	82.17%			
DecisionTreeClassifier	85.87%	86.01%	86.01%			
Random Forest Classifier	85.88%	86.17%	86.13%			
Gradient Boosting Classifier	85.93%	86.12%	86.12%			
MLPClassifier	85.89%	86.09%	86.10%			
DNN	EPOCH:15->86% .0.865809559822	EPOCH:6->86% 0.869071900844	0.8764449358			
Xgboost	85.85%	86.02%	86.02			





資料前處理

資料比較

1 資料處理

2 建立模型

3 DEMO

总包括

Credit Predict

取數值&類別的欄位

```
# 取數值 & 類別的欄位

data_num_cols = dataset_data._get_numeric_data().columns

data_cat_cols = dataset_data.columns.difference(data_num_cols)

print("Numeric columns: ", data_num_cols)

print()

print("Categorical columns: ", data_cat_cols)

Numeric columns: Index(['Age', 'Vintage', 'Avg_Account_Balance'], dtype='object')

Categorical columns: Index(['Credit_Product', 'Is_Active', 'Occupation'], dtype='object')
```



類別欄位值轉數值

```
from sklearn.preprocessing import LabelEncoder

label = LabelEncoder()

data_cat_data = data_cat_data.apply(LabelEncoder().fit_transform)
```

```
data_num_data_s.reset_index(drop=True, inplace=True)
data_cat_data.reset_index(drop=True, inplace=True)
#df = pd.concat([df1, df2], axis=1)

data_new = pd.concat([data_num_data_s, data_cat_data], axis = 1)
```



數值欄位數值標準化

#利用StandardScaler標準化

```
from sklearn import preprocessing
s_scaler = preprocessing. StandardScaler()

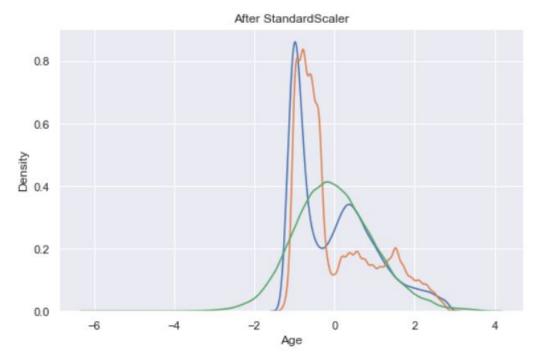
data_num_data_s = s_scaler.fit_transform(data_num_data)

data_num_data_s = pd. DataFrame(data_num_data_s, columns = data_num_cols)

fig. (ax1) = plt.subplots(ncols=1, figsize=(8, 5))

ax1.set_title('After StandardScaler')

sns.kdeplot(data_num_data_s['Age'], ax=ax1)
sns.kdeplot(data_num_data_s['Vintage'], ax=ax1)
sns.kdeplot(data_num_data_s['Avg Account Balance'], ax=ax1);
```





STOME

<u>數據樣本中, 發現有正/負資料比例佔不平均, 竟而影響到機器學習之模型失效,</u> <u>使準確率下降。在實際生活案例中, 存在問題的樣本一般會遠少於正常樣本。</u> <u>故, 透過Synthetic Minority Oversampling Technique, 在少數類樣本之間利用差值來產</u> <u>生額外的樣本</u>



Credit Predict

STOME

將資料分成訓練集(TrainDataset)以及測試資料集(TestDataset)

```
# 因為測試資料沒有答案無法判斷模型的優劣所以用此方法判斷模型優劣
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X_sm, y_sm, test_size=0.2, random_state=15, stratify=y_sm)
```

訓練資料80% 測試資料

<u> 20%</u>





SMOTE

建立模型

模型比較

1 資料處理

2 建立模型

3 DEMO



Credit Predict

建立模型

設定預測目標變數與解釋變數

In [7]:

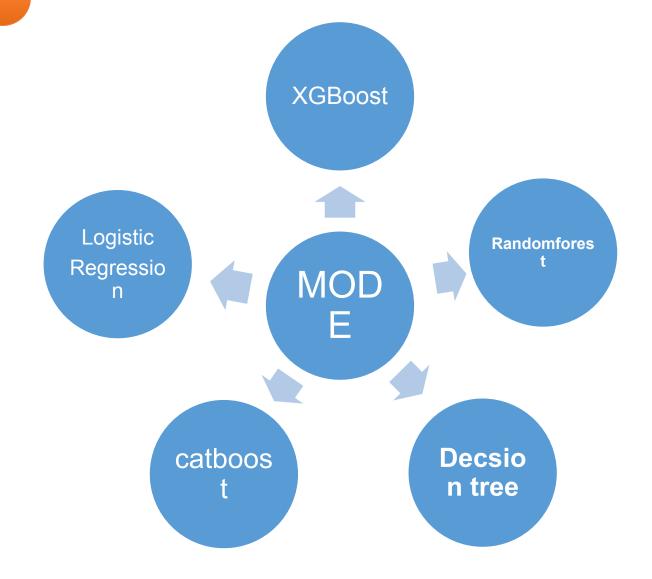
```
#設定預測目標變數與解釋變數
dataset_data = dataset.drop('Is_Lead', axis = 1)
dataset_target = dataset['Is_Lead']

#Survived為series, か入 []轉成dataframe
dataset_target2 = dataset[['Is_Lead']]

dataset_data.shape, dataset_target2.shape
```



建立模型





資料比較

同一參數							
	資料離散化	連續資料標準化	只對數值資料標準	資料離散化 SMOTE	連續資料標準化 SMOTE	只對數值資料標準化 SMOTE	
LogisticRegression	85.04%	85.03%	85.03%	71.26%	70.81%	70.93%	85.04
SGDClassifier	84.77%	84.96%	85.03%	71.75%	70.87%	70.17%	
KNeighbors Classifier	85.19%	85.46%	85.31%	72.51%	73.62%	73.68%	
GaussianNB	80.64%	80.15%	80.15%	69.16%	70.10%	69.88%	
MultinomialNB	84.63%	84.63%		70.60%	70.64%		
BernoulliNB	82.26%	84.64%	82.17%	68.45%	69.84%	68.54%	
Decision Tree Classifier	85.87%	86.01%	86.01%	74.94%	77.32%	78.12%	86.3
Random Forest Classifier	85.88%	86.17%	86.13%	75.84%	79.66%	80.32%	86.3
Gradient Boosting Classifier	85.93%	86.12%	86.12%	80.69%	81.47%	80.32%	
MLPClassifier	85.89%	86.09%	86.10%	73.00%	75.57%	74.79%	
DAIN .	EPOCH:15->86	% EPOCH:6->86%	N 0 07 C 4 4 4 0 2 F 0	0.763303007	0.7040704620	0.705	
Xgboost	85.85%	86.02%	86.02	83.70%	90.85%	91.08%	89.6

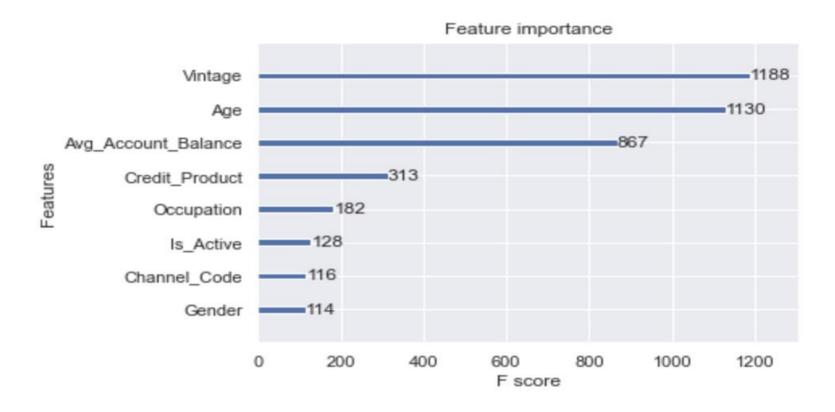
Catboost:

85.68%



Credit Predict

特徵值比較



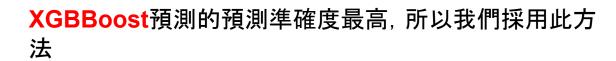
由特徵值可以看到Region_code,Gender,Channel_Code比較不重要

所以將這三個欄位刪除



模型比較

	資料離散化	連續資料標準化	資料離散化 SMOTE	連續資料離散化 SMOTE
XGBBoost	85.85%	86.02%	83.70%	<u>89.60%</u>
Randomforest	85.88%	86.17%	75.84%	79.66%
Decision Tree	85.87%	86.01%	74.94%	77.32%
CatBoost	85.80%	86.12%	無法做出	無法做出
Logistic Regression	85.04%	85.03%	71.26%	70.81%







Linebot實現

資料處理

建立模型

3 DEMO



Linebot實現



Linebot實現





結語

資料處理

建立模型

Demo

總結



User Experience Innovation Design

- 1. 使用者研究
 - 2. 概念發想
 - 3。情境模擬
 - 4. 原型製作
 - 5. 策略藍圖

KJ Method

對象:銀行; 描述問題(現 況、包含數據):識別可能 對銀行推薦的信用卡表 現出更高意向的客戶,以減少銷售成本,提升 效率; (Alan)

對象 銀行 不知道 客戶的特徵 沒辦 法對症下藥 (HSUAN)

對象: 員工。問題描述: 預測出可能會辦卡的消 費者,僅對他們推銷, 可以減少對不會辦卡的 推銷時間 (Jenny)

對象:銀行 問題: 沒有辦 看出資料中淺在地有用 資訊(將資料轉資訊)甚麼 樣的值的組合可能會有 十麼樣的現象(HSUAN)

加獲利

對象:銀行問題:從同卷通 項中,找出與要辦卡原 顧嚴高的選項,並尋找 此理項較高的客人來做 推翻 推銷(KEN)

戶; (Alan)

對象: 金融產品銷售員; Problem: 一般來說銷售 員其實很難一眼找出客戶 基本資料與其需求的關聯 ,頂多著重注意其購買記 錄或可以經過幾次與客戶 的交流慢慢去了解, 但這 樣就會很被動,且費時。

(Feati 淺在客

戶在哪 對象:銀行;描述 問題(現況、包含 數據):擴展銀行客

> 金融商品。 (KEN)

對象 银行 問題 現有資料 很多但是不知道哪樣的 資料對銀行有用(找淺在 資料對銀行有用(找淺在 客戶) 甚麼資料特徵比較 重要 (HSUAN)

銀行資料價 值不知道在 瑯裡

負評

對象:銀行業者: Problem: 找出 淺在用戶是一段 人力成 耗時的工作。 本高 (Feather)

對象:銀行。問題:銀行可以利用預測出會實 和不會員的客戶進行研究,找出root cause? 普產品 (Jenny)

對象: 消費者。問題: 1少非TA用戶接到推翻 K活機會,使其經免減 客户对公司的数据指 (Jenny)

資料 不足

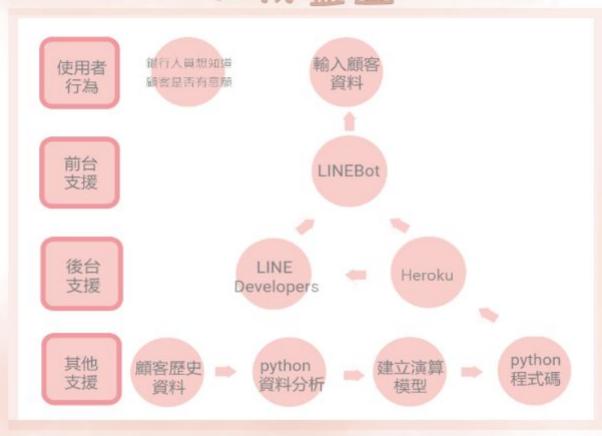
引急:銀行、問題: 进高如何旅順客 互問其的意識。

銷售 員 描述如何推銷者人,想讓客人買

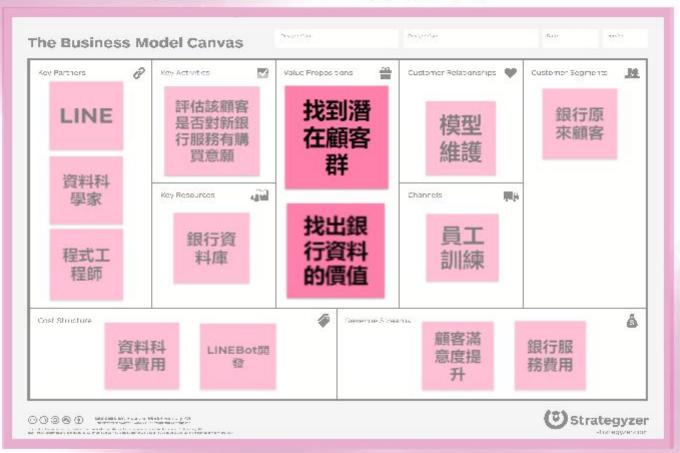
主管



服務藍圖



Business model



Thank you for watching